



ÉCOLE CENTRALE LYON

ALGORITHMES ET RAISONNEMENT
BE
RAPPORT

Analyse des sentiments par l'IA

Élèves :

Ulysse KOECHLIN
Hugo PUYBAREAU
Mattéo ROUSSEAU
Emile WEJROCH

Enseignant :

Emmanuel DELLANDREA

8 mai 2024

Table des matières

1	Introduction	2
2	Analyse de sentiments pour la modération sur les réseaux sociaux	2
2.1	Base de donnée	2
2.1.1	Récupération des données	2
2.1.2	Pré-processing des données	3
2.2	L'analyse par le deep learning	3
2.2.1	Présentation du deep learning	3
2.2.2	Comment est-il actuellement utilisé ?	4
2.2.3	Fonctionnement des algorithmes séparateurs à vastes marges	6
3	Analyse de sentiments pour la satisfaction client	9
3.1	Contexte et outils fournis par les réseaux sociaux	10
3.2	Solution proposée par l'étude pour l'analyse des données	10
4	Conclusion	11

1 Introduction

L'intelligence artificielle est un domaine scientifique qui permet à travers différentes techniques et théories de reproduire un comportement d'intelligence humaine à travers des outils matériels comme un ordinateur. Ses applications sont très nombreuses et couvrent de plus en plus de domaines. Certains d'entre eux sont à la frontière avec d'autres champs scientifiques comme la psychologie et la sociologie dont il est question lors de l'analyse des émotions et du comportement de l'humain. Ce rapport va tenter de résumer et d'expliquer l'avancée des recherches et des techniques mises en oeuvre pour ce qui est de l'analyse de sentiment au sein d'un texte (appelée *Sentiment Analysis* ou *Opinion Mining* dans la recherche internationale). Cette technique permet, dans des contextes précis, de classer le sentiment, l'émotion ou l'opinion qui se dégage derrière un texte. Cela correspond bien à un cadre d'usage d'intelligence artificielle puisque l'analyse de sentiment est une technique que les humains réalisent au quotidien. Cette tâche s'inscrit dans la catégorie du *Natural Language Processing* (NLP). Pour arriver à cela, il y a plusieurs groupes de techniques qui seront présentées tout au long de ce rapport.

Les domaines où l'analyse des sentiments est utile sont nombreux. Néanmoins, la majorité des recherches faites autour de l'analyse des sentiments est centrée sur la modération des réseaux sociaux ou sur la satisfaction client.

Dans les deux cas, l'analyse des sentiments est ramenée à un problème de classification.

Pour apporter du contexte à cette étude, il est nécessaire de savoir que l'analyse de sentiment est utilisée pour de multiples raisons. Les plus connues d'entre elles sont :

- **La classification binaire** "positif" / "négatif" sur un retour client dans un domaine quelconque
- **L'analyse des messages** postés sur les réseaux sociaux à des fins de modération ou d'analyse de données
- **L'analyse de news** sur les entreprises cotées en bourse pour orienter la prédiction d'un changement de cours d'action sur les marchés financiers

Cette liste non exhaustive démontre bien la pluralité des applications d'une telle intelligence artificielle. De plus, l'explosion des réseaux sociaux et de l'utilisation d'internet ayant radicalement changé les quantités de données échangées, le besoin d'utiliser une intelligence artificielle pour ce genre de tâche est devenu primordial. La portée étant grande, les moyens déployés en recherche et en mise en place depuis le début des années 2000 le sont aussi.

2 Analyse de sentiments pour la modération sur les réseaux sociaux

2.1 Base de donnée

2.1.1 Récupération des données

Pour pouvoir réaliser un traitement de données, c'est-à-dire une analyse de sentiment dans notre cas, il faut d'abord se procurer les données en question. Comme évoqué dans l'introduction, les lieux d'échange de messages en langage naturel sont nombreux mais les réseaux sociaux restent les plus communs. De plus, ces réseaux sont publics ce qui en

fait une source d'entraînement pour les modèles de machine learning / deep learning. Le plus connu en terme de place d'échange est *X* (anciennement *Twitter*) puisque le mode d'échange principal est composé d'un message public. C'est sur ce réseau que les données ont été récupérées dans l'étude [1].




FIGURE 1 – Logo de Twitter/X

2.1.2 Pré-processing des données

Une fois récupérés, les messages doivent être traités en vue de leur utilisation. Pour obtenir des résultats satisfaisants, il faut que les inputs de notre étude soient "normalisés", qu'ils n'aient pas de particularité singulière qui rende l'analyse de sentiment par l'algorithme trop complexe. Pour cela, les messages sont donc réduits à des versions simplifiées d'eux-même où les noms d'utilisateurs, certains hastags ou encore certains mots sont supprimés.

2.2 L'analyse par le deep learning

Dans cette partie, nous allons nous intéresser à l'analyse de sentiment par application de modèles de deep learning.

2.2.1 Présentation du deep learning

Le deep learning est une catégorie d'intelligence artificielle qui fait intervenir des réseaux de neurones. Ces réseaux s'inspirent directement du fonctionnement du cerveau humain pour obtenir un résultat à partir d'un ensemble d'informations. L'analogie entre les deux est très parlante : on a d'un côté des stimulus que l'on peut caractériser comme une liste d'inputs, de l'information est transmise à travers le réseau de neurones selon leur activation ou non pour arriver au bout de la chaîne sous forme de résultat.

Chaque neurone a un fonctionnement particulier : selon les informations qu'on lui transmet, une fonction d'activation calcule sa réponse binaire qu'il transmet lui-même aux neurones de la couche suivante. Cette architecture peut être vue comme une grosse fonction qui en entrée prend des variables, et qui en sortie nous donne sa réponse après avoir effectué des calculs. Selon l'architecture dans laquelle les neurones sont placés, différents schémas peuvent être mis en évidence. C'est pour cela que dans le cadre de l'analyse de sentiment, les réseaux de neurones vont permettre de renvoyer un sentiment, une émotion ou un opinion parmi lesquels ils ont été entraînés.




FIGURE 2 – Exemple d'architecture d'un réseau de neurone

La phase d'entraînement du réseau de neurone, comme évoquée précédemment, est cruciale pour son bon fonctionnement. À chaque neurone est assigné un poids, c'est-à-dire un chiffre, qui permet d'identifier l'importance de la réponse d'un neurone par rapport à la réponse des autres neurones. Lors de la création d'un réseau de neurone, ces poids sont généralement assignés tous égaux, ou aléatoirement selon les méthodes d'optimisation employées. Une fois assignés, ces poids doivent être modifiés de sorte à ce que le réseau augmente sa capacité à détecter le schéma que l'on attend qu'il détecte. Différentes méthodes d'optimisations sont utilisables, comme l'optimisation par descente de gradient, ou encore l'optimisation par utilisation d'algorithmes génétiques.

2.2.2 Comment est-il actuellement utilisé ?

À l'heure actuelle, la majorité des méthodes de classification utilisées sont des méthodes de classification "manuelle" [2]. En effet, la polarité des sentiments est annotée de manière manuelle. Les ingénieurs se basent sur des listes de mots ou des lexiques construits selon des catégories logiquement corrélées aux intentions et sentiments de l'auteur (positif/négatif, péjoratif/mélioratif, ...). De nombreuses recherches sont faites dans ce domaine, notamment sur l'amélioration des lexiques.

En s'intéressant au rapport [3], nous découvrant que les méthodes de classificateurs SVM sont souvent utilisées pour la création de lexiques. Ces classificateurs sont conçus pour identifier les sentiments des messages entiers ou des termes spécifiques au sein de ces messages. Les différents aspects innovants trouvés dans ce rapport sont les suivants :

- **Création de Lexiques de Sentiments** : Lexiques Basés sur les Hashtags : Utilisation de hashtags dans les tweets pour générer des lexiques qui associent des mots à des sentiments positifs ou négatifs.
- **Lexiques Basés sur les Émoticônes** : Exploitation des émoticônes pour créer des lexiques à partir de tweets, où les émoticônes servent d'indicateurs de sentiment.
- **Utilisation de SVM** : Les classificateurs à vecteurs de support (ou algorithmes à vastes marges, SVM) ont été choisis pour leur efficacité prouvée dans la catégorisation de textes.

- **Caractéristiques Lexicales et Formelles** : Intégration de n-grammes [4] de mots et de caractères (*Un n-gramme est une sous-séquence de n éléments construite à partir d'une séquence donnée*), d'URLs normalisées, de mentions d'utilisateurs, ainsi que l'usage de lexiques de sentiments pour enrichir les vecteurs de caractéristiques.
- **Fonctionnalités de Contexte** : Analyse du contexte autour des termes clés pour améliorer la détection de sentiments, en tenant compte de la négation et de la position des mots dans les messages.
- **Performance et Évaluation** : Les classificateurs ont, d'après le rapport, excellé dans des compétitions internationales, démontrant leur capacité à surpasser d'autres méthodes grâce à l'utilisation combinée des caractéristiques extraites et des lexiques générés automatiquement. Des tests sur des ensembles de données de tweets et de SMS ont montré l'efficacité des approches sans besoin d'ajustement supplémentaire pour différents types de textes.

Ces avancées montrent comment les techniques de traitement du langage naturel et d'apprentissage automatique peuvent être adaptées spécifiquement pour analyser le sentiment exprimé dans les communications brèves, comme les tweets, en utilisant à la fois des approches manuelles et automatiques pour la création de ressources lexicales et la mise en œuvre de modèles prédictifs robustes.

Comme expliqué précédemment, il est important d'améliorer les méthodes de création des lexiques. C'est pourquoi l'innovation présentée dans le rapport [2] est très intéressante. Ce n'est qu'à partir de ce moment que les réseaux de neurones entrent vraiment en jeu.

Le rapport [2] détaille donc l'avancement de l'apprentissage d'un prolongement (*translation utilisée pour Embedding même si peu précise*) de mots spécifique au sentiment (*Sentiment-Specific Word Embedding SSWE*) pour la classification de sentiments sur *Twitter*, une approche significativement innovante en analyse de sentiment.

Traditionnellement, les algorithmes d'apprentissage de prolongements de mots se concentraient sur les contextes syntaxiques sans tenir compte des informations sentimentales, conduisant à des représentations peu efficaces pour la classification de sentiments où la polarité est cruciale.

Le *SSWE* aborde cette lacune en intégrant des informations sentimentales dans les représentations continues des mots, utilisant trois architectures neuronales pour modéliser cette intégration. Les données d'entraînement proviennent de tweets massivement collectés via une supervision distante, utilisant des émoticônes comme indicateurs de sentiment positif ou négatif. Cette méthode permet d'obtenir des données sans annotations manuelles coûteuses.

La méthode *SSWE* utilise trois architectures de réseaux neuronaux distinctes pour incorporer les informations sentimentales dans les plongements de mots :

- **SSWEh (Sentiment-Specific Word Embedding with Hard constraints)** : Ce modèle intègre directement les informations sentimentales en utilisant une couche *softmax* [5] pour prédire la distribution des sentiments d'un texte à partir d'un n-gramme donné. Cela permet d'encoder explicitement la polarité sentimentale dans le vecteur de mots.
- **SSWEr (Sentiment-Specific Word Embedding with Relaxed constraints)** : À la différence de *SSWEh*, *SSWEr* utilise une fonction de perte de marge (*hinge loss*) [6] pour relâcher les contraintes sur la distribution exacte des sentiments. Ce

modèle vise à prédire si un texte est plus positif que négatif ou l'inverse, sans se fixer sur une distribution précise.

- **SSWEu (Unified Sentiment-Specific Word Embedding)** : Ce modèle est une combinaison des deux premiers. Il utilise à la fois les contextes syntaxiques et les informations sentimentales. *SSWEu* génère un vecteur à deux dimensions pour chaque n-gramme : une pour le score du modèle de langue et l'autre pour le score de sentiment. Les deux scores sont optimisés simultanément pour capturer à la fois la syntaxe et la sentimentalité.

Les modèles sont entraînés via une procédure de rétropropagation standard, où les paramètres sont ajustés en utilisant l'algorithme *AdaGrad* [7], bien adaptée pour gérer les taux d'apprentissage individuels pour chaque paramètre.

Le *SSWE* a été évalué sur un ensemble de données standard de classification de sentiment *Twitter*. Les résultats montrent que même utilisé seul, *SSWE* atteint des performances comparables à des systèmes utilisant des caractéristiques conçues manuellement. De plus, en combinant *SSWE* avec d'autres jeux de caractéristiques existants, les performances de classification sont améliorées, indiquant que *SSWE* apprend des représentations de mots qui sont à la fois riches en informations syntaxiques et sentimentales.

En résumé, *SSWE* représente une avancée significative en intégrant efficacement les informations sentimentales dans les prolongements de mots, ce qui prouve son utilité et son efficacité dans les tâches de classification des sentiments sur des plateformes sociales telles que *Twitter*.

2.2.3 Fonctionnement des algorithmes séparateurs à vastes marges

Les algorithmes séparateurs à vastes marges (SVM) sont des algorithmes dit d'apprentissages supervisés, qui ont pour but d'être un classifieur. Il ne s'agit pas à proprement parler d'intelligence artificielle comme on l'entendrait pour un réseau de neurones. Les SVM sont une méthode mathématico-informatique, qui n'est absolument pas capable d'apprentissage ou d'intelligence au sens où un humain peut apprendre ou faire preuve d'intelligence. On parle d'algorithmes supervisés car les bases de données d'entraînement doivent être étiquetées en fonction des différentes classes étudiées. Ces algorithmes ont pour but de régler des paramètres permettant en suite de savoir si un élément appartient à telle ou telle classe. Dans la suite du problème, nous allons expliquer le principe de ces algorithmes pour un problème à 2 classes qui sera plus facile à comprendre.

Problème à 2 classes : Pour visualiser le problème, une idée assez naturelle consiste à essayer de séparer les points rouges (sentiment de colère) et bleus (sentiment de peur) par une droite. À noter qu'il existe en général une infinité de droites possibles. L'idée des SVM est de choisir celle qui a la marge maximale - la marge désignant la distance entre la droite et le ou les points qui en sont le plus proche. Ce choix va permettre aux SVM de bien généraliser le classement de nouvelles données. Les points pour lesquels la marge est atteinte sont appelés vecteurs de support - auxquels la méthode doit son nom en anglais (Support Vector Machine). Dans un problème, de plus grande dimension on imagine que chacune des informations constituent une dimension. Les données sont donc mis sous la forme de vecteur de R^n auquel on associe une étiquette (quand il n'y a que deux classes on choisit en général -1 et 1) en fonction de la classe à laquelle appartient

cette donnée. L'algorithme va alors chercher l'hyperplan maximisant la marge. Il s'agit là d'un problème d'optimisation convexe comme vu dans le cours d'Analyse Appliquée de l'ECL mathématiques et dans le papier [9]. Pour la résolution théorique pure demande beaucoup de technique et d'utiliser des outils mathématiques assez avancées. D'un point de vue pratique, l'algorithme va chercher à optimiser certains paramètres en fonction entre autres des conditions de Karush-Kuhn-Tucker. L'algorithme va alors converger vers une solution qui n'est pas forcément la solution optimale. Ces algorithmes fonctionnent très bien même avec peu de données d'entraînement et peuvent être facilement ajuster avec l'arrivée de nouvelles données.

Mise en place pratique sur un exemple en 3 dimensions : Pour illustrer notre propos, nous avons décidé de mettre en place l'algorithme sur un ensemble de données séparables en 3 dimensions. Pour cela, nous avons utilisé le pseudo-code fournit dans le cours [10]. Nous avons généré les données à l'aide du module sklearn.




FIGURE 3 – Exemple de résultat

Données non-séparables : Pour le moment, nous avons toujours supposé que les deux classes pouvaient être séparés par un hyperplan. Hors ce n'est pas toujours le cas comme on peut le voir dans la figure suivante :




FIGURE 4 – Exemple donnée non séparable par un hyperplan

Dans ces cas là, on utilise le coup du noyau (ou Kernel-Trick en anglais) [11], on applique aux données une fonction Kernel qui va remplacer le produit scalaire utilisé habituellement dans R^n et plonger les données dans un ensemble de dimension supérieur. On peut même plonger les données dans des ensembles de dimension infini avec le kernel de Gauss $(x, y) \longrightarrow e^{-\frac{\|x-y\|^2}{2\sigma^2}}$. Cette astuce peut être utilisée même dans des cas séparables pour faciliter le travail de l'algorithme. Par contre pour bien réussir à rendre les données séparables il faut choisir un bon Kernel ce qui peut parfois être compliqué. Malgré tout on peut obtenir des résultats très intéressants comme sur la figure suivante :




FIGURE 5 – Kernel de Gauss donnée non séparable en 2D

Pour conclure sur les SVMs, ceux sont des algorithmes très puissants qui permettent de résoudre de manière peu complexe de problème qui le sont. De plus ces algorithmes s'adaptent facilement à beaucoup de type de donnée. En ce qui concerne l'analyse de sentiment, comme il suffit de classer la donnée entre différents types de sentiments, ces algorithmes sont parfaitement adaptés.

3 Analyse de sentiments pour la satisfaction client

L'intelligence artificielle est aussi très prisée par les entreprises privées pour mesurer la satisfaction client, que cela soit à propos d'un produit, d'une marque, d'une expérience... La part la plus importante de données est piochée dans les réseaux sociaux : c'est ce que l'on appelle l'analyse des réseaux sociaux, en anglais *social media analytics*. Il s'agit d'enregistrer et d'analyser les données diffusées sur les réseaux sociaux, principalement à des fins économiques [8].

Ce concept comprend deux catégories importantes : une première est économique, l'objectif est d'être rentable. Ainsi, pour une entreprise qui veut sortir un produit, il lui faut analyser le marché, connaître le bon timing pour sortir son produit, mais aussi analyser les réactions des consommateurs aux produits similaires déjà existants pour améliorer le sien avant sa sortie. Puis, après la sortie du produit, l'entreprise doit pouvoir analyser les retours sur son produit, suivre le nombre de gens qui l'ont aimé, ont interagi etc.

La deuxième catégorie est d'ordre technique : comment extraire toutes ces données ? Comment décider quelles sont les bonnes, les moins bonnes ? Quelles données correspondent à des avis positifs, négatifs (classification binaire) ?

Nous nous basons sur l'étude [8] pour étudier l'analyse de sentiments pour la satisfaction client.

3.1 Contexte et outils fournis par les réseaux sociaux

Les réseaux sociaux fournissent déjà initialement toute une batterie de données, accessibles aux individus comme aux entreprises : ce sont *Twitter Analytics*, *Facebook Insights*, *YouTube Analytics*, *Google Alerts*... Par exemple, *Twitter Analytics* montre le nombre de tweets faits par un utilisateurs, ses impressions, ses visites, ses mentions, ses réactions etc. Il est d'ailleurs à noter que le réseau social *Twitter* est parfois préféré aux autres réseaux sociaux pour l'analyse des sentiments : en effet, les utilisateurs y sont en moyenne plus âgés et plus actifs que sur Facebook, et peuvent donc être plus susceptible d'avoir des avis fiables [8]. L'étude [8] ne porte ainsi que sur *Twitter*.

3.2 Solution proposée par l'étude pour l'analyse des données

Pour étudier leur solution, les auteurs l'appliquent à un nombre fini de tweets, en cherchant un mot-clé et en stockant tous les tweets reliés à ce mot-clé dans une base de données. Les auteurs effectuent ensuite un prétraitement des tweets, c'est-à-dire qu'ils vont enlever le "bruit" des tweets : ce sont les informations qui ne sont pas utiles pour l'analyse de sentiments, tels que des caractères, des mots... Ainsi, lors de ce prétraitement, les émoticônes sont classés en quatre catégorie selon qu'ils sont considérés comme étant extrêmement positifs, positifs, extrêmement négatifs ou négatifs ; les acronymes et abréviations sont transformés en mots complets, selon une base de données tirée d'une autre étude (A. Agarwal, "Sentiment Analysis of Twitter Data," in In : Proc. ACL 2011 Workshop on Languages in Social Media, 2010 .) ; chaque mot est ensuite classé par type, selon qu'il est un nom, un adjectif, un verbe ou un adverbe. Son type et sa position dans la phrase donnent alors au mot un score, allant de -8 (négatif) à +8 (positif). C'est la *SentiWord List*, une liste de mots anglais ainsi classés ; enfin, les auteurs utilisent une liste, appelée *Stop List*, qui énumère les mots qui leurs sont inutiles pour l'analyse des sentiments, tels que *a* (un/une), *the* (le/la), *with* (avec), *and* (et), *or* (ou), *I* (je), *you* (tu, toi, vous)...

Après cela, les espaces sont supprimés et les caractères spéciaux et URL, mentions etc. sont remplacés par d'autres caractères reconnaissables, comme sur la FIGURE 6 ci-dessous, présentant le résultat du prétraitement.

Tweet	#Wearables Apple Music reportedly strikes deal with popular social media app Musical.ly :D :D https://t.co/mobfOW1YIS... https://t.co/9bJGxs986r
Pre-processed	H wearables N POS apple N POS music R POS reportedly V POS strikes V POS deal A POS popular A POS social N POS media N POS application P P A POS musical N POS love U U

FIGURE 6 – Résultat du prétraitement, tiré de [8]

On divise ensuite le tweet en mots : l'ensemble des mots restants sont les éléments d'une liste, qui forme le tweet prétraité. C'est ce que les auteurs appellent le *feature bag*, le sac de caractéristiques. Le tweet prétraité (sous forme de liste) au complet, lui, forme

un vecteur de caractéristiques. Un exemple de *Feature bag* est donné sur la FIGURE 7 ci-dessous.

Unigram Feature Bag	{ wearables, apple, music, reportedly, strikes, popular, social, media, application, love }
------------------------------------	--

FIGURE 7 – *Feature bag* du tweet précédemment prétraité, tiré de [8]

Les mots-clés sont ensuite analysés via la méthode SVM. En entraînement de l'algorithme, ils sont alors labellisés +1 si le tweet est classé positif, -1 s'il est classé négatif. En test de l'algorithme, par contre, chaque tweet qui n'a pas déjà été labellisé sera comparé à un ensemble de mots issus de tweets labellisés durant la phase d'entraînement pour prédire la classification du nouveau tweet.

4 Conclusion

Dans la conclusion, il est important de souligner comment l'analyse de sentiment s'inscrit dans le cadre de l'intelligence artificielle et du traitement du langage naturel. Cette technique permet de reproduire un aspect essentiel du comportement humain : la capacité à interpréter et à comprendre les émotions et les opinions exprimées dans un texte. En effet, l'analyse de sentiment est un exemple concret de l'application des principes de l'intelligence artificielle dans des domaines interdisciplinaires tels que la psychologie et la sociologie.

Au fil du rapport, nous avons exploré les différentes techniques utilisées pour réaliser l'analyse de sentiment, allant des approches traditionnelles comme l'analyse lexicale aux méthodes plus avancées basées sur l'apprentissage automatique et l'intelligence artificielle. Ces techniques ont été présentées dans le contexte du traitement du langage naturel (NLP), soulignant ainsi l'importance de comprendre et d'interpréter le langage humain pour réaliser cette tâche. L'analyse de sentiments via l'intelligence artificielle a de multiples utilisations possibles : régulation des réseaux sociaux, études de marché... Ces analyses reposent sur des algorithmes utilisant le *deep-learning* et le *natural language processing*, comme le SVM dont le fonctionnement a été expliqué dans ce rapport.

En résumé, l'analyse de sentiment représente un domaine crucial de l'intelligence artificielle, offrant des possibilités d'application diverses dans des domaines tels que le marketing, la politique et la veille stratégique. En continuant à explorer et à développer ces techniques, nous pourrions non seulement améliorer notre compréhension des sentiments et des opinions exprimées dans les textes, mais également ouvrir de nouvelles perspectives pour l'intégration de l'intelligence artificielle dans notre société.

Références

- [1] **Sentiment Analysis using Machine Learning : Progress in the machine intelligence for data science** de *G. Revathy, Saleh A. Alghamdi, Sultan M. Alahmari, Saud R. Yonbawi, Anil Kumar et Mohd Anul Haq*, 2022.
- [2] **Learning Sentiment-Specific Word Embedding for Twitter Sentiment Classification** de *Duyu Tang, Furu Wei, Nan Yang, Ming Zhou, Ting Liu et Bing Qin*, Research Center for Social Computing and Information Retrieval Harbin Institute of Technology, China, 2014. Lien PDF
- [3] **Building the State-of-the-Art in Sentiment Analysis of Tweets** de *Saif M. Mohammad, Svetlana Kiritchenko, and Xiaodan Zhu*, National Research Council Canada, 2013. Lien PDF
- [4] **N-gramme** de *Wikipédia*, fin 2023. Lien
- [5] **Softmax** de *Wikipédia*, 2024. Lien
- [6] **Hinge Loss** de *Wikipédia*, 2024. Lien
- [7] **Ada Grad** de *DataBricks*, 2024. Lien
- [8] **Customer Satisfaction Measurement using Sentiment Analysis** de *Shaha Al-Otaibi, Allulo Alnassar, Asma Alshahrani, Amany Al-Mubarak, Sara Albugami, Nada Almutiri and Aisha Albugami*, International Journal of Advanced Computer Science and Applications(ijacs), 9(2), 2018. Lien
- [9] **Sequential Minimal Optimization : A Fast Algorithm for Training Support Vector Machines** de *John Platt*, 1998. Lien
- [10] **CS229 Simplified SMO Algorithm** de *Stanford*, 2021.
- [11] **Astuce du noyau** de *Wikipédia*, 2024. Lien